

结构因果模型 (SCM) 与概率基础

——从形式化定义到马尔可夫过程的统一视角

学习笔记

2026 年 2 月 1 日

目录

1	结构因果模型 (SCM) 的形式化定义	2
2	测度论视角：从“背景空间”到“观测世界”	2
2.1	背景空间与笛卡尔积	2
2.2	解函数与原像 (Pre-image)	3
3	干预计算：严谨的三步走算法	3
4	结构形式 vs. 约简形式	4
5	SCM 与随机过程：马尔可夫链的嵌入	4
5.1	马尔可夫链的 SCM 构造	4
5.2	实例：非线性状态依赖系统	5
6	总结	5

1 结构因果模型 (SCM) 的形式化定义

结构因果模型 (Structural Causal Model) 是描述系统因果机制的数学框架。不同于纯粹的统计模型，SCM 强调变量生成的方向性和机制性。

SCM 的四元组定义

一个结构因果模型 M 由四元组 $\langle \mathbf{U}, \mathbf{V}, \mathcal{F}, P(\mathbf{U}) \rangle$ 构成：

1. **外生变量 (Exogenous Variables) $\mathbf{U}$** : 又称背景变量 (Background Variables)。它们是系统的“根节点”，其生成机制在模型之外。
2. **内生变量 (Endogenous Variables) $\mathbf{V}$** : 模型内部的变量，其值由模型内的机制决定。
3. **结构方程 (Structural Equations) $\mathcal{F}$** : 一组函数 $\{f_v\}_{v \in \mathbf{V}}$ ，对于每个内生变量 $V_i \in \mathbf{V}$ ，都有：

$$v_i = f_i(pa_i, u_i) \quad (1)$$

其中 $pa_i \subseteq \mathbf{V} \setminus \{V_i\}$ 是 V_i 的父节点 (直接原因)， $u_i \subseteq \mathbf{U}$ 是相关的背景噪声。

4. **背景分布 (Background Distribution) $P(\mathbf{U})$** : 外生变量上的概率分布。通常假设 U 的各个分量相互独立。

注 1.1. 在外生变量层面，我们通常假设它们是独立的。如果发现 U_X 和 U_Y 不独立，说明模型不完备，存在未观测的共同原因 (Latent Confounder)。

2 测度论视角：从“背景空间”到“观测世界”

为了严谨地理解概率是如何在 SCM 中传播的，我们需要引入测度论的视角。

2.1 背景空间与笛卡尔积

假设系统有 k 个外生变量 $U_1, \dots, U_k$ ，每个变量的取值空间为 $\mathcal{D}_i$ 。整个系统的基础样本空间 (Sample Space) Ω 是这些外生变量空间的笛卡尔积：

$$\Omega = \mathcal{D}_1 \times \mathcal{D}_2 \times \dots \times \mathcal{D}_k \quad (2)$$

空间中的每一点 $\omega = (u_1, u_2, \dots, u_k)$ 代表了一个确定的世界状态。其上的概率测度 $P(\omega)$ 是各分量测度的乘积 (基于独立性假设)。

2.2 解函数与原像 (Pre-image)

在一个无环的 SCM 中，任何内生变量 V 最终都可以被写成只关于 ω 的函数，这称为约简形式 (Reduced Form) 或 解函数：

$$v = h(\omega)$$

当我们询问“ V 落在集合 S 中的概率是多少”时，我们实际上是在进行如下三步操作：

1. **映射**：通过 h 将背景空间映射到观测空间。
2. **反解 (Pullback)**：寻找目标集合 S 在背景空间中的原像 E ：

$$E = h^{-1}(S) = \{\omega \in \Omega \mid h(\omega) \in S\}$$

3. **称重 (Integration)**：计算集合 E 的概率测度：

$$P(V \in S) = \int_E dP(\omega)$$

注 2.1 (关于非满射与不可知性)。如果映射 h 不是满射，意味着观测空间中某些状态 y^* 在背景空间 Ω 中没有对应的原像 ($h^{-1}(y^*) = \emptyset$)。根据公理， $P(\emptyset) = 0$ 。这代表在该因果机制下，状态 y^* 绝不可能发生，而非“概率不可知”。

3 干预计算：严谨的三步走算法

当我们执行干预 $do(X = x_0)$ 时，我们实际上是在修改结构方程 $\mathcal{F}$ ，将 $x = f_x(\dots)$ 替换为 $x = x_0$ 。计算干预后概率 $P(Y = y \mid do(X = x_0))$ 的形式化步骤如下：

三步算法 (Substitution-Inversion-Integration)

1. 代入 (Substitution) —— 建立新映射

在 Y 的结构方程中，将 X 强行替换为常量 x_0 。 Y 变成了关于背景变量 U 的新函数：

$$Y_{x_0}(u) = f_Y(x_0, f_Z(u_Z), u_Y)$$

此时， $Z \rightarrow X$ 的路径被切断。

2. 反解 (Inversion) —— 圈定集合

在背景空间 Ω 中，寻找满足条件的所有外生变量组合（幕后黑手集合）：

$$S_{do} = \{(u_Z, u_Y) \in \Omega \mid f_Y(x_0, f_Z(u_Z), u_Y) = y\}$$

这里包括了那些在自然观测下可能永远不会导致 $X = x_0$ 的样本（反事实样本）。

3. 称重 (Integration) —— 积分求和

利用原始的背景分布 $P(U)$ 对集合 S_{do} 进行加权：

$$P = \int_{S_{do}} dP(u)$$

对于离散情况，这通常体现为后门准则： $\sum_z P(Y|x_0, z)P(z)$ 。

4 结构形式 vs. 约简形式

一个常见的疑问是：既然外生变量决定一切，为什么不直接只写 $Y = h(U)$ ？

- **约简形式 (Reduced Form):** $Y = h(U)$ 。
 - 描述了“果”与“根”的终极关系。
 - 对于**观测 (Prediction)**是充分的。只要 U 确定， Y 就确定。
- **结构形式 (Structural Form):** $Y = f(X, U_Y), X = g(U_X)$ 。
 - 描述了因果作用的**路径**。
 - 对于**干预 (Intervention)**是必须的。中间变量 X 提供了“干预的手柄”。如果只有约简形式，我们无法模拟 $do(X)$ ，因为 X 在方程中消失了。

5 SCM 与随机过程：马尔可夫链的嵌入

现代随机过程（如马尔可夫链）通常描述状态间的概率转移 $P(X_{t+1}|X_t)$ 。在 SCM 框架下，我们需要将其**重参数化 (Reparameterization)** 为确定性机制。

5.1 马尔可夫链的 SCM 构造

对于任意马尔可夫转移 $P(X_{t+1}|X_t)$ ，我们总能构造一个 SCM：

$$X_{t+1} = f(X_t, U_{t+1}) \tag{3}$$

- U_{t+1} 是独立同分布的外生噪声（例如 $U \sim \text{Unif}[0, 1]$ 或 $\mathcal{N}(0, 1)$ ）。
- f 是确定性函数，将当前状态和噪声映射为下一状态。

5.2 实例：非线性状态依赖系统

考虑如下复杂的动力系统：

$$X_{n+1} = \alpha \tanh(X_n) + (1 + \beta X_n^2) \xi_{n+1}$$

在 SCM 中：

- **节点**: X_n 为内生变量, U_n (即 ξ_n) 为外生变量。
- **结构**: $X_n \rightarrow X_{n+1}$, 且 $U_{n+1} \rightarrow X_{n+1}$ 。
- **因果含义**: X_n 是 X_{n+1} 的直接原因。如果我们 $do(X_n = c)$, 则我们切断了 $X_{n-1} \rightarrow X_n$ 的联系, 强行将系统状态置为 c , 并按上述方程演化。

6 总结

SCM 提供了一种统一的语言：

1. 它用**集合论与测度论**严谨定义了概率的来源（外生变量的笛卡尔积）。
2. 它用**结构方程**区分了“相关”与“因果”（能否进行 do 运算）。
3. 它完全兼容并包含了现代随机过程，赋予了它们反事实推理的能力。