

技术手册：因果推断的基础与结构模型

Causal Inference: Foundations and Structural Models

版本：1.0

适用对象：科研人员、数据科学家

January 30, 2026

Contents

1	第一章：接口层——操作化定义 (Operational Definition)	3
1.1	1.1 核心定义	3
1.2	1.2 定义的两范式	3
1.2.1	A. 测量的操作化 (Measurement Operations)	3
1.2.2	B. 实验的操作化 (Experimental Operations)	3
1.3	1.3 质量控制标准	4
1.4	1.4 数学映射：潜变量与代理变量	4
1.5	1.5.1 概率视角：变量即函数	5
1.6	1.5.2 因果视角：变量即节点	5
1.7	1.5.3 符号系统的严格约定	5
2	第二章：核心层——结构因果模型 (SCM)	6
2.1	2.1 模型的本体论定义	6
2.2	2.2 赋值算子与非对称性	7
2.3	2.3 图形化表示 (DAG)	7
3	第三章：操作层——干预与图手术	8
3.1	3.1 观察 vs. 干预	8
3.2	3.2 图手术 (Graph Surgery)	8
3.3	3.3 根本不等式与混杂	8

4	第四章：推理层——因果阶梯 (The Ladder of Causation)	10
4.1	4.1 第一层级：关联 (Association)	10
4.2	4.2 第二层级：干预 (Intervention)	10
4.3	4.3 第三层级：反事实 (Counterfactuals)	10

1 第一章：接口层——操作化定义 (Operational Definition)

在进入数学模型之前，我们需要解决最基础的问题：如何将现实世界中模糊的概念 (Concept) 转化为模型可以处理的数据 (Data)。这就是操作化定义的作用——它是理论世界与经验世界的接口。

1.1 1.1 核心定义

定义：操作化定义

操作化定义是指不直接描述一个概念的本质，而是通过描述**测量**或**操控**该概念所需的具体操作程序 (Operations/Procedures) 来定义它。

核心原则：如果一个概念无法被操作化（无法转化为具体的测量步骤），则该概念在科学实证研究中被视为**无意义 (Meaningless)**。

1.2 1.2 定义的两范式

1.2.1 A. 测量的操作化 (Measurement Operations)

针对**因变量**或**状态指标**。解决“如何读取数值”的问题。

示例：智力

- **非操作化**：处理抽象信息的能力。
- **操作化**：在斯坦福-比奈智力量表上的标准得分。

1.2.2 B. 实验的操作化 (Experimental Operations)

针对**自变量**或**处理手段**。解决“如何产生状态”的问题。

示例：高温环境

- **非操作化**：很热的地方。
- **操作化**：在一个封闭的、恒温控制为 $45^{\circ}\text{C} \pm 0.5^{\circ}\text{C}$ 的气候箱中停留 20 分钟。

1.3 1.3 质量控制标准

在定义操作时，必须通过以下两个指标的考核：

1. 信度 (Reliability) ——一致性

- 测试方法：多次测量同一对象，结果是否相同？
- 隐喻：尺子的刻度是否固定，不会忽长忽短。

2. 效度 (Validity) ——准确性

- 测试方法：操作化得到的变量是否真实反映了那个潜在的构念？
- 隐喻：你拿的是尺子（测长度），而不是温度计（测温度）。

1.4 1.4 数学映射：潜变量与代理变量

在建模视角下，操作化定义建立了从**潜变量**到**代理变量**的函数关系。

- 令 U 为 **潜变量 (Latent Variable)**：真实的、不可测的构念（如真实健康状况）。
- 令 X 为 **代理变量 (Proxy Variable)**：操作化得到的观测值（如体检报告得分）。
- 令 ϵ 为 **测量误差 (Measurement Error)**。

操作化定义即函数 f ：

$$X = f(U, \epsilon) \tag{1}$$

警告

在后续的因果建模中，永远记住 $X \neq U$ 。严谨的模型会专门引入测量误差节点来处理这种差异。

第 1.5 节补充：数学基础——变量的严谨定义

在日常语言中，“变量”指代变化的数值。但在概率论与因果推断中，我们需要从测度论的高度对其进行定义。

1.5 1.5.1 概率视角：变量即函数

在严谨的数学定义中，**随机变量 (Random Variable)** 并非一个数，而是一个**函数**。

定义：随机变量

设 $(\Omega, \mathcal{F}, P)$ 为概率空间，其中 Ω 为样本空间（所有可能结果的集合）。
一个实值随机变量 X 是一个从样本空间映射到实数集的**可测函数**：

$$X : \Omega \rightarrow \mathbb{R} \quad (2)$$

物理直觉：

- $\omega \in \Omega$ 代表世界的**真实微观状态**（上帝视角，即前文提到的潜变量）。
- $X(\omega)$ 代表我们在该状态下**观测到的数值**。
- **结论：**变量本质上是某种“测量机制”在数学上的抽象。

1.6 1.5.2 因果视角：变量即节点

在结构因果模型 (SCM) 中，变量被视为因果图中的**节点**，并根据生成机制分为两类：

1. 外生变量 (Exogenous, U):

- 没有任何父节点。
- 它们直接承载了系统的不确定性，对应于概率定义中的 ω 。

2. 内生变量 (Endogenous, V):

- 由结构方程生成的变量。
- 本质上，它们是外生变量的**复合函数**。

1.7 1.5.3 符号系统的严格约定

在阅读文献和公式时，必须严格区分大小写：

符号	名称	含义与语境
X (大写)	随机变量	代表整个函数或分布。用于 $H(X), I(X; Y), X \rightarrow Y$ 。
x (小写)	具体取值	代表函数的一个输出值。用于 $P(X = x), do(X = x)$ 。
$\mathcal{X}$ (花体)	字母表	代表 x 所有可能取值的集合 (Support)。

2 第二章：核心层——结构因果模型 (SCM)

一旦完成了变量的操作化定义，我们就有了数据。现在，我们需要一套数学语言来描述这些变量是如何相互作用、相互生成的。这就是 Judea Pearl 提出的 SCM。

2.1 2.1 模型的本体论定义

一个结构因果模型 M 由三个集合构成一个三元组：

$$M = \langle U, V, F \rangle \quad (3)$$

1. U (Exogenous Variables) 外生变量集：

- 模型的边界。它们由模型外部因素决定，我们不解释其成因，通常视为“背景噪声”或“运气”。
- 数学上，需要定义 U 上的概率分布 $P(U)$ 。

2. V (Endogenous Variables) 内生变量集：

- 模型内部决定的变量。每一个 V_i 都是至少一个外生变量和其他内生变量的后代。

3. F (Structural Equations) 结构方程集：

- 描述机制的核心。对于每一个内生变量 $V_i \in V$ ，都存在一个对应的函数 $f_i \in F$ ：

$$v_i = f_i(pa_i, u_i) \quad (4)$$

- 其中 $pa_i \subseteq V \setminus \{V_i\}$ 是 V_i 的父节点 (Parents)，即直接原因。

2.2 2.2 赋值算子与非对称性

这是理解因果性的关键门槛。在 SCM 中，方程中的等号 $=$ 实际上代表编程语言中的赋值算子 (Assignment Operator, $:=$)。

- **代数方程**： $Y = \alpha X$ 与 $X = Y/\alpha$ 是等价的。信息是双向流动的。
- **结构方程**： $Y := \alpha X$ 表示一种物理机制。
 - 它意味着：自然界先查看 X 的值，经过计算，赋值给 Y 。
 - **不对称性 (Asymmetry)**：改变 X 会导致 Y 变化；但改变 Y 不会导致 X 变化（除非有逆向的物理机制专门负责）。

2.3 2.3 图形化表示 (DAG)

每一个 SCM 都可以关联一个 有向无环图 (DAG) G 。

- **节点**：代表变量 V 。
- **有向边**：代表函数依赖。如果 X 出现在 f_Y 的参数列表中，则画一条 $X \rightarrow Y$ 的箭头。

3 第三章：操作层——干预与图手术

这是因果推断区别于传统统计学的核心操作。

3.1 3.1 观察 vs. 干预

我们需要区分两个概率算子：

1. 条件概率 (Seeing): $P(Y|X = x)$

- **语义**：在自然产生的数据中，找到 $X = x$ 的子集，观察 Y 的分布。
- **比喻**：Excel 里的“筛选”功能。

2. 干预概率 (Doing): $P(Y|do(X = x))$

- **语义**：强制将 X 的值固定为 x （切断其原本的成因），观察 Y 的分布。
- **比喻**：实验室里的“强制给药”。

3.2 3.2 图手术 (Graph Surgery)

在数学上，如何定义 $do(X = x)$ ？通过对 SCM 进行“手术”。假设原模型 M 包含方程 $X = f_X(Z, U_X)$ 。执行 $do(X = x)$ 会生成一个新的子模型 M_x ：

手术步骤

1. **删除 (Delete)**：在 F 中，删除决定 X 的那个方程 f_X 。
 - 图形意义：剪断所有**指向** X 的箭头（入边）。
2. **替换 (Replace)**：用常数方程 $X = x$ 替代。
 - 图形意义： X 变成一个没有父节点的根节点。
3. **保持 (Keep)**：其他所有变量的方程 $f_Y, f_Z...$ 保持不变。

3.3 3.3 根本不等式与混杂

因果效应定义的根本不等式：

$$P(Y|X) \neq P(Y|do(X)) \quad (5)$$

- **差异来源**：混杂因子 (Confounder)。即同时影响 X 和 Y 的变量。
- **统计推断** ($P(Y|X)$) 会包含非因果路径（后门路径）的信息，导致虚假相关。
- **因果推断** ($P(Y|do(X))$) 通过图手术阻断了混杂路径，只保留了 $X \rightarrow Y$ 的纯因果效应。

4 第四章：推理层——因果阶梯 (The Ladder of Causation)

Judea Pearl 将因果认知能力划分为三个层级。

4.1 4.1 第一层级：关联 (Association)

- **行为**：观察 (Seeing)。
- **问题**：如果我看到 X 发生了，由于关联性，我对 Y 的信念会如何改变？
- **数学形式**： $P(y|x)$ 。
- **应用**：机器学习预测、相关性分析。

4.2 4.2 第二层级：干预 (Intervention)

- **行为**：行动 (Doing)。
- **问题**：如果我强制让 X 发生，会导致 Y 发生什么改变？
- **数学形式**： $P(y|do(x))$ 。
- **应用**：A/B 测试、药物疗效评估。

4.3 4.3 第三层级：反事实 (Counterfactuals)

- **行为**：想象 (Imagining)。
- **问题**：假如过去我做了 X （实际上我没做），结果 Y 会有什么不同？
- **数学形式**： $P(y_x|x', y')$ 。
- **推演步骤 (Abduction-Action-Prediction)**:
 1. **溯因**：根据事实 (x', y') 反推外生变量 U （背景特征）。
 2. **行动**：修改模型，执行 $do(X = x)$ 。
 3. **预测**：利用第一步得到的 U 和第二步的模型，计算新的 Y 。

附录：关键术语对照表

中文术语	英文术语	符号	物理含义
操作化定义	Operational Definition	$X = f(U)$	测量程序、落地标准
结构方程	Structural Equation	$v_i = f_i(pa_i, u_i)$	生成机制、自然法则
外生变量	Exogenous Variable	U	背景、噪声、未观测因素
干预	Intervention	$do(X = x)$	实验操控、图手术
反事实	Counterfactual	$Y_{X=x}(u)$	假设性思考、后悔药