

结构因果模型 (SCM) 深度研读笔记

——从公理定义到通信系统实战

致追求严谨的探索者

2026 年 1 月 30 日

目录

1 引言	2
2 SCM 的公理化定义	2
3 实战案例：自适应调制 (AMC) 的陷阱	3
3.1 场景设定	3
3.2 构建 SCM 模型	3
3.2.1 1. 因果图结构	3
3.2.2 2. 具体的结构方程与参数	3
4 计算对比：观测 vs. 干预	4
4.1 1. 统计观测视角 (Association)	4
4.2 2. 因果干预视角 (Intervention)	4
4.3 3. 结果对比	5
5 总结	5

1 引言

本文档旨在严格定义 Judea Pearl 的结构因果模型 (Structural Causal Model, SCM), 并通过一个非平凡的通信工程案例 (自适应调制), 展示如何通过 “干预算子” 计算出与传统统计学截然不同的结果。

2 SCM 的公理化定义

一个结构因果模型 M 被定义为一个四元组:

$$M = \langle U, V, F, P(u) \rangle$$

定义: 1. 变量集合 (Variables)

变量被严格划分为两类:

- 外生变量集 (Exogenous Variables) U :** 这是模型的边界。我们不解释 U 的生成原因, 只接受其统计特性。它们是 “背景噪声”。
- 内生变量集 (Endogenous Variables) V :** 这是模型内部的变量。它们的每一个值都由模型内的机制决定。

定义: 2. 结构方程 (Structural Equations) F

F 是一个函数集合 $\{f_1, \dots, f_n\}$, 对于每一个内生变量 $V_i \in V$, 都存在一个对应的方程:

$$v_i \leftarrow f_i(pa_i, u_i) \quad (1)$$

其中:

- $pa_i \subseteq V \setminus \{V_i\}$ 是 V_i 的父节点 (直接原因)。
- $u_i \subseteq U$ 是影响 V_i 的外生干扰。
- $\leftarrow$ 代表**赋值** (非对称), 而非代数等号。

深度洞察: 因果与相关的本质区别

在代数中, $Y = X + 1$ 等价于 $X = Y - 1$ 。

但在 SCM 中, $Y \leftarrow X + U$ 意味着改变 X 会改变 Y , 但改变 Y **绝不会**物理上改变 X 。这种不对称性是因果推断的核心。

3 实战案例：自适应调制 (AMC) 的陷阱

3.1 场景设定


考虑一个无线通信系统，我们三个变量：

1. 信道质量 Z (SNR): 干扰因子 (Confounder)。
2. 调制阶数 X (Modulation): 这是我们的策略变量 (如 QPSK vs 16QAM)。
3. 误码率 Y (BER): 这是我们关注的结果。

系统是 ** 自适应 ** 的：当信道 Z 变好时，算法会自动提高调制阶数 X 以提升速率。

3.2 构建 SCM 模型

3.2.1 1. 因果图结构



3.2.2 2. 具体的结构方程与参数

为了能够手算，我们定义离散的数值模型（简化版）：

A. 外生变量分布 $P(U)$: 假设信道好坏各占一半。

$$Z := U_Z, \quad P(Z = 0 \text{ [差]}) = 0.5, \quad P(Z = 1 \text{ [好]}) = 0.5$$

B. 调制策略 $X := f_X(Z, U_X)$: 系统倾向于在好信道用高阶调制 ($X = 1$)，差信道用低阶 ($X = 0$)。

$$P(X = 1|Z) = \begin{cases} 0.9 & \text{若 } Z = 1 \text{ (好信道, 激进策略)} \\ 0.1 & \text{若 } Z = 0 \text{ (差信道, 保守策略)} \end{cases}$$

C. 误码率物理机制 $Y := f_Y(Z, X, U_Y)$: 我们将误码率量化为数值（越小越好）。假设数值如下：

- 好信道 ($Z = 1$):
 - 低阶 $X = 0$: $Y = 0.1$ (极好)
 - 高阶 $X = 1$: $Y = 0.4$ (一般, 因为阶数高了)
- 差信道 ($Z = 0$):

- 低阶 $X = 0$: $Y = 0.5$ (勉强)
- 高阶 $X = 1$: $Y = 0.9$ (崩溃)

实战案例：我们的任务

我们要回答的问题是：“全面强制使用高阶调制 ($X = 1$)，会导致误码率上升还是下降？”

4 计算对比：观测 vs. 干预

这是见证奇迹的时刻。我们将分别计算统计期望 $E[Y|X]$ 和因果期望 $E[Y|do(X)]$ 。

4.1 1. 统计观测视角 (Association)

计算 $E[Y|X = 1]$ 。这是我们在日志里看到的“使用高阶调制时的平均误码率”。

利用贝叶斯公式，我们先算出 $X = 1$ 发生的总概率：

$$P(X = 1) = P(X = 1|Z = 1)P(Z = 1) + P(X = 1|Z = 0)P(Z = 0)$$

$$P(X = 1) = 0.9 \times 0.5 + 0.1 \times 0.5 = 0.45 + 0.05 = 0.5$$

现在计算条件期望：

$$\begin{aligned} E[Y|X = 1] &= \sum_z E[Y|X = 1, Z = z]P(Z = z|X = 1) \\ &= 0.4 \times P(Z = 1|X = 1) + 0.9 \times P(Z = 0|X = 1) \end{aligned}$$

其中后验概率为：

$$P(Z = 1|X = 1) = \frac{P(X = 1|Z = 1)P(Z = 1)}{P(X = 1)} = \frac{0.9 \times 0.5}{0.5} = 0.9$$

$$P(Z = 0|X = 1) = \frac{P(X = 1|Z = 0)P(Z = 0)}{P(X = 1)} = \frac{0.1 \times 0.5}{0.5} = 0.1$$

代入计算：

$$E[Y|X = 1] = 0.4 \times 0.9 + 0.9 \times 0.1 = 0.36 + 0.09 = \mathbf{0.45}$$

深度洞察：直觉欺骗

数据告诉我们：当你使用高阶调制时，平均误码率只有 0.45。看起来还不错！但这主要是因为 ** 只有信道好的时候我们才敢用高阶调制 **。

4.2 2. 因果干预视角 (Intervention)

计算 $E[Y|do(X = 1)]$ 。这意味着我们 ** 砍断 ** $Z \rightarrow X$ 的连线，强行在所有情况下设 $X = 1$ 。

根据后门准则 (Backdoor Adjustment):

$$P(Y|do(X=1)) = \sum_z P(Y|X=1, Z=z)P(Z=z)$$

注意: 这里权重变成了 $P(Z)$ 而不是 $P(Z|X)$, 因为干预打破了 Z 和 X 的相关性。

$$\begin{aligned} E[Y|do(X=1)] &= E[Y|X=1, Z=1]P(Z=1) + E[Y|X=1, Z=0]P(Z=0) \\ &= 0.4 \times 0.5 + 0.9 \times 0.5 \\ &= 0.2 + 0.45 \\ &= \mathbf{0.65} \end{aligned}$$

4.3 3. 结果对比

指标	数值	含义
观测 $E[Y X=1]$	0.45	“看到” 用高阶调制时的表现 (乐观)
干预 $E[Y do(X=1)]$	0.65	“强迫” 用高阶调制的真实表现 (悲观)

严谨结论

如果你基于观测数据 (0.45) 做出决策, 全面推广高阶调制, 真实的系统误码率将会飙升至 0.65。这就是忽略结构因果模型带来的代价。

SCM 揭示了: Z 是一个混杂因子, 它在观测数据中打开了一道“后门路径”($X \leftarrow Z \rightarrow Y$)。 $do(X)$ 算子通过数学上的“图手术”, 切断了这条路径, 给出了真实的因果效应。

5 总结

通过这个非平凡的例子, 我们验证了 $v_i = f_i(pa_i, u_i)$ 的核心思想:

- $pa_Y = \{X, Z\}$: 误码率的直接父亲是调制和信道。
- $P(Z)$ 的不变性: 干预 X 不会改变信道 Z 的物理分布。