

概率论与数理统计核心技术手册

——面向信息论与高阶概率分析

常用不等式 · 收敛性 · 极限定理

2026 年 1 月 25 日

目录

1 核心概率不等式 (Probability Inequalities)	2
1.1 马尔可夫不等式 (Markov's Inequality)	2
1.2 切比雪夫不等式 (Chebyshev's Inequality)	2
1.3 琴生不等式 (Jensen's Inequality)	3
2 随机变量的收敛性 (Convergence)	4
2.1 依概率收敛 (Convergence in Probability)	4
2.2 依分布收敛 (Convergence in Distribution)	4
3 极限定理 (Limit Theorems)	5
3.1 弱大数定律 (Weak Law of Large Numbers, WLLN)	5
3.2 中心极限定理 (Central Limit Theorem, CLT)	5

1 核心概率不等式 (Probability Inequalities)

本章介绍概率论中最基础的工具，它们是证明大数定律和收敛性的基石。

1.1 马尔可夫不等式 (Markov's Inequality)

这是最基础的不等式，用于建立非负随机变量的尾部概率上界。

定理 1.1 (马尔可夫不等式). 设 X 为非负随机变量，且 $\mathbb{E}[X]$ 存在。对于任意常数 $a > 0$ ，有：

$$\mathbb{P}(X \geq a) \leq \frac{\mathbb{E}[X]}{a} \quad (1)$$

证明. 定义指示函数 $I_{\{X \geq a\}}$ 。因为 $X \geq 0$ ，我们可以建立如下不等关系：

$$a \cdot I_{\{X \geq a\}} = \begin{cases} a & \text{若 } X \geq a \\ 0 & \text{若 } X < a \end{cases}$$

显然对于所有 X 的取值，都有 $a \cdot I_{\{X \geq a\}} \leq X$ 成立。两边同时取期望：

$$\mathbb{E}[a \cdot I_{\{X \geq a\}}] \leq \mathbb{E}[X]$$

由于期望的线性性质以及 $\mathbb{E}[I_A] = \mathbb{P}(A)$ ：

$$a \cdot \mathbb{P}(X \geq a) \leq \mathbb{E}[X] \implies \mathbb{P}(X \geq a) \leq \frac{\mathbb{E}[X]}{a}$$

□

1.2 切比雪夫不等式 (Chebyshev's Inequality)

该不等式量化了随机变量偏离其均值的程度，是证明弱大数定律的关键。

定理 1.2 (切比雪夫不等式). 设 X 是随机变量，期望为 μ ，方差为 $\sigma^2 < \infty$ 。对于任意 $k > 0$ ：

$$\mathbb{P}(|X - \mu| \geq k) \leq \frac{\sigma^2}{k^2} \quad (2)$$

证明. 构造非负随机变量 $Y = (X - \mu)^2$ 。我们要求的是 $\mathbb{P}((X - \mu)^2 \geq k^2)$ 。应用马尔可夫不等式（取 $a = k^2$ ）：

$$\mathbb{P}((X - \mu)^2 \geq k^2) \leq \frac{\mathbb{E}[(X - \mu)^2]}{k^2}$$

根据方差的定义 $\text{Var}(X) = \mathbb{E}[(X - \mu)^2] = \sigma^2$ ，代入即得：

$$\mathbb{P}(|X - \mu| \geq k) \leq \frac{\sigma^2}{k^2}$$

□

1.3 琴生不等式 (Jensen's Inequality)

在信息论中极为重要（用于证明 KL 散度非负性、Gibbs 不等式等）。

定理 1.3 (琴生不等式). 设 $f(x)$ 是凸函数 (*convex function*), X 是随机变量。则：

$$f(\mathbb{E}[X]) \leq \mathbb{E}[f(X)] \quad (3)$$

如果是凹函数 (*concave*, 如 $\log x$), 方向反转: $f(\mathbb{E}[X]) \geq \mathbb{E}[f(X)]$ 。

证明思路. 利用凸函数的几何性质。对于凸函数 f 在点 $\mu = \mathbb{E}[X]$ 处, 存在一条支撑线 (切线) $L(x) = a + bx$, 满足 $L(x) \leq f(x)$ 且 $L(\mu) = f(\mu)$ 。

$$\mathbb{E}[f(X)] \geq \mathbb{E}[L(X)] = \mathbb{E}[a + bX] = a + b\mathbb{E}[X] = L(\mathbb{E}[X]) = f(\mathbb{E}[X])$$

□

2 随机变量的收敛性 (Convergence)

在处理 $n \rightarrow \infty$ 的问题时，区分不同的收敛模式至关重要。

2.1 依概率收敛 (Convergence in Probability)

定义 2.1. 序列 X_n 依概率收敛于 X ，记为 $X_n \xrightarrow{p} X$ ，如果对于任意 $\epsilon > 0$ ：

$$\lim_{n \rightarrow \infty} \mathbb{P}(|X_n - X| \geq \epsilon) = 0$$

注：这正是弱大数定律和 AEP (渐进等分割性) 所使用的收敛定义。

2.2 依分布收敛 (Convergence in Distribution)

定义 2.2. 序列 X_n 依分布收敛于 X ，记为 $X_n \xrightarrow{d} X$ ，如果它们的累积分布函数满足：

$$\lim_{n \rightarrow \infty} F_n(x) = F(x)$$

对于 $F(x)$ 的所有连续点成立。

注：这是中心极限定理 (CLT) 的收敛形式。

3 极限定理 (Limit Theorems)

3.1 弱大数定律 (Weak Law of Large Numbers, WLLN)

应用场景：当你需要证明样本均值接近总体均值，或者频率接近概率时。

定理 3.1 (弱大数定律). 设 $X_1, \dots, X_n$ 是独立同分布 (*i.i.d.*) 的随机变量, $\mathbb{E}[X_i] = \mu$, $\text{Var}(X_i) = \sigma^2 < \infty$ 。令样本均值 $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ 。则 $\bar{X}_n$ 依概率收敛于 μ ：

$$\bar{X}_n \xrightarrow{p} \mu$$

即对于任意 $\epsilon > 0$, $\lim_{n \rightarrow \infty} \mathbb{P}(|\bar{X}_n - \mu| \geq \epsilon) = 0$ 。

证明. 计算样本均值的期望与方差：

$$\mathbb{E}[\bar{X}_n] = \mu, \quad \text{Var}(\bar{X}_n) = \text{Var}\left(\frac{1}{n} \sum X_i\right) = \frac{1}{n^2} \sum \text{Var}(X_i) = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}$$

直接对 $\bar{X}_n$ 应用切比雪夫不等式：

$$\mathbb{P}(|\bar{X}_n - \mu| \geq \epsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\epsilon^2} = \frac{\sigma^2}{n\epsilon^2}$$

当 $n \rightarrow \infty$ 时, 右侧趋于 0。证毕。 □

3.2 中心极限定理 (Central Limit Theorem, CLT)

应用场景：不仅要知道均值收敛，还需要知道误差的分布形状（正态分布）。

定理 3.2 (Lindeberg-Lévy CLT). 设 $X_1, \dots, X_n$ *i.i.d.*, $\mathbb{E}[X_i] = \mu$, $\text{Var}(X_i) = \sigma^2 < \infty$ 。则随机变量 $Z_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}$ 依分布收敛于标准正态分布：

$$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} N(0, \sigma^2)$$

证明梗概 (特征函数法). 设 $Y_i = \frac{X_i - \mu}{\sigma}$, 则 $\mathbb{E}[Y_i] = 0, \text{Var}(Y_i) = 1$ 。 $Z_n = \frac{1}{\sqrt{n}} \sum_{i=1}^n Y_i$ 。 Y_i 的特征函数在 0 附近的泰勒展开为：

$$\phi_Y(t) = \mathbb{E}[e^{itY}] = 1 + it\mathbb{E}[Y] - \frac{t^2}{2}\mathbb{E}[Y^2] + o(t^2) = 1 - \frac{t^2}{2} + o(t^2)$$

Z_n 的特征函数为：

$$\begin{aligned} \phi_{Z_n}(t) &= \mathbb{E}\left[e^{it \frac{1}{\sqrt{n}} \sum Y_i}\right] = \left[\phi_Y\left(\frac{t}{\sqrt{n}}\right)\right]^n \\ &\approx \left(1 - \frac{t^2}{2n}\right)^n \end{aligned}$$

当 $n \rightarrow \infty$ 时, 利用极限公式 $(1 + \frac{x}{n})^n \rightarrow e^x$ ：

$$\lim_{n \rightarrow \infty} \phi_{Z_n}(t) = e^{-t^2/2}$$

这正是标准正态分布 $N(0, 1)$ 的特征函数。根据连续性定理, 原分布收敛。 □