

Fano 不等式：从直觉到严谨

A Rigorous Walkthrough


Gemini Thought Partner

2026 年 2 月 2 日

1 0. 证明的物理图景 (The Big Picture)

我们要证明的目标是：** 如果信息的残留不确定性 $H(W|Y^n)$ 很大，那么错误率 P_e 就不可能很小。 **

因果链条 (Markov Chain) 如下：



2 1. 变量定义：从函数的角度

为了严谨，我们利用你刚刚掌握的“随机变量即函数”的观点来定义辅助变量。

概念 1：错误变量 E (Error Variable)

我们需要量化“是否出错”。定义二元随机变量 E 如下：

$$E = g(W, \hat{W}) = \begin{cases} 1, & \text{若 } W \neq \hat{W} \quad (\text{猜错了}) \\ 0, & \text{若 } W = \hat{W} \quad (\text{猜对了}) \end{cases}$$

设 $P(E = 1) = P_e$ (错误概率)。

关键洞察： E 不是独立的，它是由 W 和 $\hat{W}$ 完全确定的函数。知道了 W 和 $\hat{W}$ ，你就 100% 知道 E 是几。

3 2. 证明核心：链式法则的“左右互搏”

证明的技巧在于计算联合熵 $H(E, W|\hat{W})$ 。我们可以用两种不同的顺序（链式法则）展开它，然后令结果相等。

步骤 1: 路径 A：先看消息 W

根据链式法则 $H(X, Y) = H(X) + H(Y|X)$ ：

$$H(E, W|\hat{W}) = H(W|\hat{W}) + H(E|W, \hat{W}) \quad (1)$$

分析第二项 $H(E|W, \hat{W})$ ：

- 物理意义：已知真实答案 W 和你的猜测 $\hat{W}$ ，你对“是否出错 E ”还有疑惑吗？
- 答案：完全没有疑惑。 E 是确定性函数。
- 数学结论： $H(E|W, \hat{W}) = 0$ 。

结论 A：

$$H(E, W|\hat{W}) = H(W|\hat{W}) \quad (2)$$

步骤 2: 路径 B：先看错误 E

换个顺序展开同一个联合熵：

$$H(E, W|\hat{W}) = H(E|\hat{W}) + H(W|E, \hat{W}) \quad (3)$$

我们需要逐项放缩这两个部分。

4 3. 逐项击破 (The Inequality Logic)

现在我们要分析路径 B 中的两项。这是证明中最精彩的部分。

4.1 第一项： $H(E|\hat{W})$

这是“已知估计值时，是否出错的不确定性”。根据熵的性质（条件熵 $\leq$ 无条件熵）：

$$H(E|\hat{W}) \leq H(E) = H(P_e)$$

其中 $H(P_e)$ 是二元熵函数（最大值为 1 bit）。**直观理解**：无论你猜的是什么，你对自己“有没有猜错”的迷茫程度，绝不会超过 E 本身的随机性。

4.2 第二项: $H(W|E, \hat{W})$ (难点)

这项的意思是: 已知我猜了 $\hat{W}$, 且已知我也猜错了 ($E = 1$), 那么真实答案 W 到底是谁?

我们将这一项按 E 的取值展开定义 (条件熵的期望定义):

$$H(W|E, \hat{W}) = P(E = 0)H(W|\hat{W}, E = 0) + P(E = 1)H(W|\hat{W}, E = 1)$$

1. 当 $E = 0$ (没猜错): 这意味着 $W = \hat{W}$ 。既然已知 $\hat{W}$, 那 W 就确定了。

$$H(W|\hat{W}, E = 0) = 0$$

2. 当 $E = 1$ (猜错了): 这意味着 $W \neq \hat{W}$ 。

- 真实消息 W 可以在除了 $\hat{W}$ 之外的 $M - 1$ 个选项中取值。
- 为了让不等式成立 (考虑最坏情况/最大熵), 我们假设 W 在这 $M - 1$ 个选项中均匀分布。
- 均匀分布的熵最大, 为 $\log(\text{选项数量})$ 。

$$H(W|\hat{W}, E = 1) \leq \log(M - 1)$$

合并结果:

$$\begin{aligned} H(W|E, \hat{W}) &\leq (1 - P_e) \cdot 0 + P_e \cdot \log(M - 1) \\ &= P_e \log(M - 1) \end{aligned} \tag{4}$$

5 4. 终极组装 (Assembly)

将路径 A 的结果 (2) 和路径 B 的放缩结果 (4) 联立:

$$\underbrace{H(W|\hat{W})}_{\text{路径 A}} = \underbrace{H(E|\hat{W}) + H(W|E, \hat{W})}_{\text{路径 B}}$$

代入不等式:

$$H(W|\hat{W}) \leq H(P_e) + P_e \log(M - 1)$$

由于 $H(P_e) \leq 1$ 且 $\log(M - 1) < \log M$, 我们可以得到更宽松 (但也更常用) 的形式:

$$H(W|\hat{W}) \leq 1 + P_e \log M$$

6 5. 最后一步：数据处理不等式

我们证明的是 $H(W|\hat{W})$ ，但题目通常要求 $H(W|Y^n)$ 。回顾因果链： $W \rightarrow Y^n \rightarrow \hat{W}$ 。根据 **数据处理不等式 (Data Processing Inequality)**，处理数据只会丢失信息（增加不确定性，或者保持不变），离得越远看得越不清：

$$H(W|Y^n) \leq H(W|\hat{W})$$

(注意：条件熵越小意味着知道得越多。离 W 最近的 Y^n 包含的信息量 $\geq$ 经过加工后的 $\hat{W}$ 。这意味着 Y^n 对 W 的残留不确定性更小)。

Fano 不等式 (最终形式)

$$H(W|Y^n) \leq 1 + P_e \log M$$

物理含义：如果你想把残留不确定性 $H(W|Y^n)$ 压到 0（完美通信），除了让错误率 P_e 趋向于 0 之外，别无他法。