

Fano 不等式之补完：数据处理定理

Rigorous Proof of $H(W|Y^n) \leq H(W|\hat{W})$

Gemini Thought Partner

2026 年 2 月 3 日

1 0. 前置思考：为什么一定是马尔可夫链？

在证明开始之前，我们需要回答一个根本问题：为什么通信系统 $W \rightarrow Y^n \rightarrow \hat{W}$ 必须构成马尔可夫链？如果不构成，不等式还成立吗？

1.1 1. 物理约束：译码器的“盲视”

所谓通信，核心在于**物理隔离**。

- 发送端持有 W 。
- 接收端（译码器）物理上接触不到 W 。
- 接收端唯一能获取的信息来源是信道输出 Y^n 。

数学上，这意味着估值 $\hat{W}$ 只能是 Y^n 的函数（或者是基于 Y^n 的随机函数），而不能直接依赖于 W 。

$$\hat{W} = g(Y^n)$$

这就定义了条件独立性：

$$P(\hat{W} | Y^n, W) = P(\hat{W} | Y^n)$$

直观理解：一旦观测数据 Y^n 给定，真实的 W 到底是多少，对于生成 $\hat{W}$ 已经没有影响了（因为译码器看不见 W ）。这就是马尔可夫链 $W \rightarrow Y^n \rightarrow \hat{W}$ 的严格定义。

1.2 2. 如果不是马尔可夫链会怎样？（反证）

假设系统**不是**马尔可夫链。这意味着译码器有一条“秘密通道”可以直接偷看 W （即 $W \rightarrow \hat{W}$ 直接相连）。

反例构造：

- 设信道完全断开： Y^n 是全噪声，与 W 独立。此时 $I(W; Y^n) = 0$ 。
- 设译码器作弊：它不看 Y^n ，直接通过秘密通道照抄 W 。此时 $\hat{W} = W$ ，故 $I(W; \hat{W}) = H(W)$ 。

此时数据处理不等式 (DPI) 将变为：

$$\underbrace{I(W; Y^n)}_0 \geq \underbrace{I(W; \hat{W})}_{H(W)}$$


即 $0 \geq H(W)$ 。这显然是谬误。

结论

Fano 不等式和数据处理不等式成立的前提，就是“不能作弊”。如果不满足马尔可夫链性质，说明译码器获取了观测值 Y^n 以外的信息，那么“处理数据只会丢失信息”这一定律就不再适用，上述证明也无法完成。

2 1. 物理模型：马尔可夫链

通信系统的处理流程构成了一个标准的马尔可夫链 (Markov Chain):



定义 (马尔可夫性): 给定中间观测值 Y^n , 估计值 $\hat{W}$ 与真实值 W 是**条件独立**的。
即:

$$P(W, \hat{W} | Y^n) = P(W | Y^n) \cdot P(\hat{W} | Y^n) \quad (1)$$

这意味着：一旦知道了 Y^n , $\hat{W}$ 就不能提供关于 W 的任何**额外**信息。

3 2. 严谨证明 (基于熵的性质)

我们要证明：观测越原始，不确定性越小。

定理 1：数据处理不等式 (条件熵版)

对于马尔可夫链 $W \rightarrow Y^n \rightarrow \hat{W}$, 有:

$$H(W | Y^n) \leq H(W | \hat{W}) \quad (2)$$

证明 1: 推导过程

我们从右边 $H(W | \hat{W})$ 出发。

第一步：引入 Y^n (增加条件) 根据信息论基本定理 “**条件增加，熵不增**” (Conditioning reduces entropy):

$$H(X|Y) \geq H(X|Y, Z)$$

我们可以引入中间变量 Y^n :

$$H(W | \hat{W}) \geq H(W | \hat{W}, Y^n) \quad (3)$$

第二步：利用马尔可夫性考察项 $H(W | \hat{W}, Y^n)$ 。 由于 $W \rightarrow Y^n \rightarrow \hat{W}$, $\hat{W}$ 仅仅是 Y^n 的函数 (或随机映射)。如果在已知 Y^n 的情况下, 再知道 $\hat{W}$ 并不会消除任何关于 W 的不确定性。数学上, 这等价于 $I(W; \hat{W} | Y^n) = 0$ 。所以:

$$H(W | \hat{W}, Y^n) = H(W | Y^n) \quad (4)$$

第三步：联立将 (4) 代入 (3):

$$H(W | \hat{W}) \geq H(W | Y^n)$$

得证。

4 3. 另一种视角：互信息 (DPI)

如果你习惯使用互信息 $I(X;Y)$ ，证明会更简洁。

证明 2: 基于互信息的证明

数据处理不等式 (DPI) 指出：信息在处理过程中只会丢失，不会增加。

$$W \rightarrow Y^n \rightarrow \hat{W} \implies I(W; Y^n) \geq I(W; \hat{W})$$

将互信息展开为熵的形式 $I(A; B) = H(A) - H(A|B)$ ：

$$H(W) - H(W | Y^n) \geq H(W) - H(W | \hat{W})$$

两边同时消去 $H(W)$ （真实消息的熵）：

$$-H(W | Y^n) \geq -H(W | \hat{W})$$

两边乘以 -1 ，不等号方向改变：

$$H(W | Y^n) \leq H(W | \hat{W})$$

得证。

5 4. 直观解释 (The Intuition)

厨师理论

- W ：原始的一头猪。
- Y^n ：刚买回来的生猪肉（包含猪的信息最多）。
- $\hat{W}$ ：厨师做好的红烧肉（丢失了很多原始信息，如猪毛颜色、猪的叫声）。

结论：看着“红烧肉”猜这头猪长什么样 ($H(W|\hat{W})$)，肯定比看着“生猪肉”猜 ($H(W|Y^n)$) 要**难**。**难**就意味着**不确定性 (熵) 更大**。