

信息论基础：渐进分析与渐进等分性 (AEP)

学习笔记

2026 年 1 月 23 日

1 引言

本教程旨在严格推导信息论中的核心极限定理——渐进等分性 (Asymptotic Equipartition Property, AEP)。我们将不涉及具体的编码方案，而是专注于随机序列随长度 $n \rightarrow \infty$ 时的统计行为。核心思想是：在高维空间中，随机向量的分布并非散乱无章，而是高度集中在一个特定的子集上。

2 数学预备知识

在讨论 AEP 之前，我们需要严格定义随机变量序列的收敛性以及大数定律。

定义 2.1 (依概率收敛, Convergence in Probability). 设 $Z_1, Z_2, \dots$ 为一列随机变量， α 为常数。若对于任意给定的 $\epsilon > 0$ ，都有：

$$\lim_{n \rightarrow \infty} \mathbb{P}(|Z_n - \alpha| > \epsilon) = 0 \quad (1)$$

则称序列 Z_n **依概率收敛** 于 α ，记作 $Z_n \xrightarrow{P} \alpha$ 。

定理 2.1 (弱大数定律, Weak Law of Large Numbers, WLLN). 设 $X_1, X_2, \dots, X_n$ 为独立同分布 (i.i.d.) 的随机变量序列，其数学期望 $\mathbb{E}[X_i] = \mu < \infty$ 。定义样本均值为 $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ 。则当 $n \rightarrow \infty$ 时：

$$\bar{X}_n \xrightarrow{P} \mu \quad (2)$$

即样本均值依概率收敛于数学期望。

3 渐进等分性 (AEP)

AEP 是“大数定律在信息论中的直接体现”。它描述了长序列概率的对数行为。

3.1 基本定义

定义 3.1 (信息随机变量). 设 X 为离散随机变量, 其概率质量函数为 $p(x)$ 。定义 X 的对数似然的负数为随机变量 $\log \frac{1}{p(X)}$ 。其期望即为熵:

$$\mathbb{E} \left[\log \frac{1}{p(X)} \right] = H(X) \quad (3)$$

定理 3.1 (渐进等分性, AEP). 若 $X_1, X_2, \dots, X_n$ 是 *i.i.d.* 的随机变量序列, 服从分布 $p(x)$, 则:

$$-\frac{1}{n} \log p(X_1, X_2, \dots, X_n) \xrightarrow{P} H(X) \quad (4)$$

严谨推导. 由于 X_i 独立, 序列 $X^n = (X_1, \dots, X_n)$ 的联合概率为:

$$p(X^n) = \prod_{i=1}^n p(X_i)$$

对该联合概率取负对数并归一化:

$$-\frac{1}{n} \log p(X^n) = -\frac{1}{n} \log \prod_{i=1}^n p(X_i) = -\frac{1}{n} \sum_{i=1}^n \log p(X_i)$$

定义新的随机变量 $Y_i = -\log p(X_i)$ 。由于 X_i 是 *i.i.d.* 的, 函数变换后的 Y_i 也是 *i.i.d.* 的。计算 Y_i 的期望:

$$\mathbb{E}[Y_i] = \sum_x p(x)(-\log p(x)) = H(X)$$

现在的表达式变为 Y_i 的算术平均值:

$$-\frac{1}{n} \log p(X^n) = \frac{1}{n} \sum_{i=1}^n Y_i$$

根据弱大数定律 (WLLN), 样本均值依概率收敛于期望:

$$\frac{1}{n} \sum_{i=1}^n Y_i \xrightarrow{P} \mathbb{E}[Y_i] = H(X)$$

证毕。 □

4 典型集 (Typical Set)

AEP 定理是关于随机变量收敛的描述, 而**典型集**是该定理在集合论与几何上的直观体现。这是理解香农理论最关键的几何概念。

定义 4.1 (典型集). 对于任意 $\epsilon > 0$ 和序列长度 n , 定义典型集 $A_\epsilon^{(n)}$ 为满足以下条件的序列 $x^n \in \mathcal{X}^n$ 的集合:

$$2^{-n(H(X)+\epsilon)} \leq p(x^n) \leq 2^{-n(H(X)-\epsilon)} \quad (5)$$

该不等式等价于:

$$\left| -\frac{1}{n} \log p(x^n) - H(X) \right| \leq \epsilon \quad (6)$$

注. 直观理解: 典型集包含了那些“既不太可能发生, 也不太不可能发生”的序列。它们的概率惊人地一致, 都接近 $2^{-nH(X)}$ 。

4.1 典型集的性质

以下三个性质是严格推导后续所有定理的基础。

性质 4.1 (概率集中性). 当 n 足够大时, 观测到的序列属于典型集的概率接近于 1。

$$\mathbb{P}(A_\epsilon^{(n)}) > 1 - \epsilon, \quad \text{对于充分大的 } n \quad (7)$$

证明. 这直接由 AEP 定义 (依概率收敛) 得出。依概率收敛意味着偏差大于 ϵ 的概率趋于 0, 因此偏差小于等于 ϵ 的概率趋于 1。□

性质 4.2 (集合势的上界). 典型集中序列的个数 $|A_\epsilon^{(n)}|$ 有上界:

$$|A_\epsilon^{(n)}| \leq 2^{n(H(X)+\epsilon)} \quad (8)$$

证明. 利用全概率公式:

$$1 \geq \sum_{x^n \in A_\epsilon^{(n)}} p(x^n)$$

在典型集中, 每个序列的概率都有下界 $p(x^n) \geq 2^{-n(H(X)+\epsilon)}$ 。代入得:

$$1 \geq \sum_{x^n \in A_\epsilon^{(n)}} 2^{-n(H(X)+\epsilon)} = |A_\epsilon^{(n)}| \cdot 2^{-n(H(X)+\epsilon)}$$

两边同乘 $2^{n(H(X)+\epsilon)}$ 即得证。□

性质 4.3 (集合势的下界). 典型集中序列的个数 $|A_\epsilon^{(n)}|$ 有下界:

$$|A_\epsilon^{(n)}| \geq (1 - \epsilon) 2^{n(H(X)-\epsilon)}, \quad \text{对于充分大的 } n \quad (9)$$

证明. 根据性质 1, 对于充分大的 n , $\mathbb{P}(A_\epsilon^{(n)}) > 1 - \epsilon$ 。即:

$$\sum_{x^n \in A_\epsilon^{(n)}} p(x^n) > 1 - \epsilon$$

在典型集中, 每个序列的概率都有上界 $p(x^n) \leq 2^{-n(H(X)-\epsilon)}$ 。代入得:

$$|A_\epsilon^{(n)}| \cdot 2^{-n(H(X)-\epsilon)} \geq \sum_{x^n \in A_\epsilon^{(n)}} p(x^n) > 1 - \epsilon$$

移项整理得:

$$|A_\epsilon^{(n)}| \geq (1 - \epsilon) 2^{n(H(X)-\epsilon)}$$

□

5 总结与几何解释

通过上述推导，我们建立了如下几何图像：

1. **全集很大**：序列空间 $\mathcal{X}^n$ 的总元素个数是 $|\mathcal{X}|^n = 2^{n \log |\mathcal{X}|}$ 。
2. **典型集很小**：典型集的大小约为 $2^{nH(X)}$ 。由于 $H(X) \leq \log |\mathcal{X}|$ ，当 n 很大时，典型集只是全集微乎其微的一个子集。
3. **概率集中**：尽管典型集很小，但它却几乎包含了所有的概率质量（接近 1）。
4. **均匀分布假象**：在典型集内部，所有序列发生的概率几乎相等（约为 $2^{-nH(X)}$ ）。

这种“大概率集中在小集合”上的现象，是高维概率空间的普遍特征。