

信息论基础：信源编码定理 (Shannon I)

严谨推导教程

2026 年 1 月 24 日

目录

1	核心概念澄清：信源 vs 信道	2
2	预备知识：AEP 回顾	2
3	香农第一定理（无失真信源编码定理）	2
4	严谨证明（利用 AEP）	2
4.1	编码方案构造	3
4.2	平均码长推导	3
4.3	取极限	4
5	直观解释	4

1 核心概念澄清：信源 vs 信道

在进入证明之前，我们必须严格区分两个概念：

- **信源编码 (Source Coding)**：本章内容。目的是**数据压缩**。利用数据的统计特性（熵），用最短的平均码长表示信源。
- **信道编码 (Channel Coding)**：下一阶段内容。目的是**纠错**。在数据中人为加入冗余，以对抗噪声。

关系：现代通信系统通常串联使用：

信源 $\xrightarrow{\text{压缩}}$ 信源编码 $\xrightarrow{\text{保护}}$ 信道编码 $\xrightarrow{\text{传输}}$...

2 预备知识：AEP 回顾

我们在之前的教程中已经证明了渐进等分性（AEP）。对于独立同分布（i.i.d.）信源 $X^n = (X_1, \dots, X_n)$ ，当 $n \rightarrow \infty$ 时：

1. **典型集定义**： $A_\epsilon^{(n)} = \{x^n : |-\frac{1}{n} \log p(x^n) - H(X)| < \epsilon\}$
2. **概率集中**： $P(A_\epsilon^{(n)}) > 1 - \epsilon$
3. **集合大小**： $|A_\epsilon^{(n)}| \leq 2^{n(H(X)+\epsilon)}$

这告诉我们：尽管所有可能的序列有 $|\mathcal{X}|^n$ 个，但真正大概率出现的“典型序列”，只有 $2^{nH(X)}$ 个。

3 香农第一定理（无失真信源编码定理）

定理 3.1. 设信源 X 的熵为 $H(X)$ 。

- **正定理**：只要编码速率 $R > H(X)$ ，这就存在一种编码方案，使得当 $n \rightarrow \infty$ 时，错误解码的概率趋于 0（或平均码长任意接近 $H(X)$ ）。
- **逆定理**：若 $R < H(X)$ ，则无论如何编码，错误概率必趋于 1。

4 严谨证明（利用 AEP）

我们采用“**分块编码**”的思想。我们将所有长度为 n 的序列分为两类：“典型序列”和“非典型序列”。

4.1 编码方案构造

对于每一个生成的序列 x^n :

1. 情况 1: 如果 $x^n \in A_\epsilon^{(n)}$ (是典型序列)

- 我们给它分配一个短的二进制码。
- 由于典型集大小 $\leq 2^{n(H(X)+\epsilon)}$, 我们需要 $\lceil n(H(X)+\epsilon) \rceil$ 个比特来区分它们。
- 为了标志这是一个典型序列, 我们在前面加一个 **0**。
- **总长度:** $l(x^n) \leq n(H(X)+\epsilon) + 2$ (加 1 位标志, 加 1 位取整)。

2. 情况 2: 如果 $x^n \notin A_\epsilon^{(n)}$ (是非典型序列)

- 我们对这些序列进行暴力编码 (枚举)。
- 序列总数为 $|\mathcal{X}|^n$, 需要 $\lceil n \log |\mathcal{X}| \rceil$ 个比特。
- 为了标志这是一个非典型序列, 我们在前面加一个 **1**。
- **总长度:** $l(x^n) \leq n \log |\mathcal{X}| + 2$ 。

4.2 平均码长推导

我们要计算序列的平均码长 $L_n = \mathbb{E}[l(X^n)]$:

$$L_n = \sum_{x^n} p(x^n) l(x^n) \quad (1)$$

将其拆分为典型集部分和非典型集部分:

$$L_n = \sum_{x^n \in A_\epsilon^{(n)}} p(x^n) l(x^n) + \sum_{x^n \notin A_\epsilon^{(n)}} p(x^n) l(x^n) \quad (2)$$

利用 AEP 的性质:

- $P(A_\epsilon^{(n)}) \leq 1$
- $P((A_\epsilon^{(n)})^c) < \epsilon$ (对于充分大的 n)

代入上述长度界限:

$$\begin{aligned} L_n &\leq \underbrace{1 \cdot [n(H(X)+\epsilon) + 2]}_{\text{典型序列贡献}} + \underbrace{\epsilon \cdot [n \log |\mathcal{X}| + 2]}_{\text{非典型序列贡献}} \\ &= nH(X) + n\epsilon + 2 + n\epsilon \log |\mathcal{X}| + 2\epsilon \end{aligned}$$

我们关注平均每个符号的码长 $\frac{L_n}{n}$:

$$\frac{L_n}{n} \leq H(X) + \epsilon + \frac{2}{n} + \epsilon \log |\mathcal{X}| + \frac{2\epsilon}{n} \quad (3)$$

4.3 取极限

当 $n \rightarrow \infty$ 时, $\frac{1}{n}$ 项趋于 0。

$$\lim_{n \rightarrow \infty} \frac{L_n}{n} \leq H(X) + \epsilon + \epsilon \log |\mathcal{X}|$$

由于 ϵ 可以任意小, 我们令 $\epsilon \rightarrow 0$, 则:

$$\lim_{n \rightarrow \infty} \frac{L_n}{n} \leq H(X) \quad (4)$$

5 直观解释

为什么能压缩?

想象你要传输一段英文文章。

- **AEP 告诉我们:** “the”, “and”, “is” 等词出现的概率极高 (典型序列)。
- **编码策略:** 给高频的 “the” 分配极短的码 (如 00), 给极罕见的 “zipper” 分配长码。
- **结果:** 虽然偶尔会遇到长词, 但因为我们大部分时间都在传短词, 所以平均下来的长度非常短, 这就是熵 $H(X)$ 。