

信息熵作为平均码长下确界的严谨证明

信息论笔记

January 21, 2026

1 1. 问题定义

设 X 为一个离散随机变量，其样本空间为 $\mathcal{X} = \{x_1, x_2, \dots, x_m\}$ ，对应的概率分布为 $p_i = P(X = x_i)$ 。

我们要对 X 进行 D 进制编码 (D -ary coding)，码字字母表大小为 D (例如 $D = 2$ 为二进制， $D = q$ 为有限域 $\mathbb{F}_q$)。设 l_i 为样本 x_i 对应的码长。平均码长定义为：

$$L = \sum_{i=1}^m p_i l_i \quad (1)$$

我们定义 D 进制信息熵为：

$$H_D(X) = - \sum_{i=1}^m p_i \log_D p_i \quad (2)$$

目标：证明 $H_D(X)$ 是所有唯一可译码 (Uniquely Decodable Codes) 平均码长的下确界 (Infimum)。即证明：

$$H_D(X) = \inf\{L(C) \mid C \text{ 是唯一可译码}\} \quad (3)$$

这包含两个部分：

1. **下界性：**对任意唯一可译码， $L \geq H_D(X)$ 。
2. **可逼近性：**存在编码序列使得平均码长无限逼近 $H_D(X)$ 。

2 2. 第一部分：证明它是下界 ($L \geq H_D(X)$)

定理 1 (香农第一定理逆定理). 对于任意满足 Kraft 不等式的唯一可译码，其平均码长 L 满足 $L \geq H_D(X)$ 。

Proof. 我们要考查 $L - H_D(X)$ 的差值：

$$L - H_D(X) = \sum_i p_i l_i - \left(- \sum_i p_i \log_D p_i \right) \quad (4)$$

$$= \sum_i p_i l_i + \sum_i p_i \log_D p_i \quad (5)$$

$$= \sum_i p_i \log_D (D^{l_i}) + \sum_i p_i \log_D p_i \quad (6)$$

$$= \sum_i p_i \log_D (p_i \cdot D^{l_i}) \quad (7)$$

$$= \sum_i p_i \log_D \left(\frac{p_i}{D^{-l_i}} \right) \quad (8)$$

利用自然对数不等式 $\ln x \leq x - 1$ (或者 $-\ln x \geq 1 - x$)，我们将底数换为 e 并应用不等式：

$$L - H_D(X) = \frac{1}{\ln D} \sum_i p_i \ln \left(\frac{p_i}{D^{-l_i}} \right) \quad (9)$$

$$= -\frac{1}{\ln D} \sum_i p_i \ln \left(\frac{D^{-l_i}}{p_i} \right) \quad (10)$$

$$\geq -\frac{1}{\ln D} \sum_i p_i \left(\frac{D^{-l_i}}{p_i} - 1 \right) \quad (\text{应用 } \ln x \leq x - 1) \quad (11)$$

$$= -\frac{1}{\ln D} \left(\sum_i D^{-l_i} - \sum_i p_i \right) \quad (12)$$

根据 Kraft 不等式 $\sum D^{-l_i} \leq 1$ 以及概率归一化 $\sum p_i = 1$ ，我们有：

$$\sum_i D^{-l_i} - \sum_i p_i \leq 1 - 1 = 0 \quad (13)$$

由于前面的系数带有负号，因此：

$$L - H_D(X) \geq 0 \implies L \geq H_D(X) \quad (14)$$

等号成立当且仅当 $D^{-l_i} = p_i$ ，即 $l_i = -\log_D p_i$ 。□

3. 第二部分：证明它是下确界 (逼近定理)

由于 l_i 必须为整数，单个符号编码通常无法取到等号。我们需要引入**信源扩展 (Source Extension)** 或**块编码 (Block Coding)** 来证明 $H_D(X)$ 可以被任意逼近。

定理 2 (渐进等同性). 对于信源 X 的 N 次扩展 X^N ，存在编码策略使得平均每个符号的码长 L_N/N 满足：

$$\lim_{N \rightarrow \infty} \frac{L_N}{N} = H_D(X) \quad (15)$$

Proof. 考虑对序列 $X^N = (X_1, X_2, \dots, X_N)$ 进行整体编码。这是一个新的“超符号”，其概率为 $P(x^N) = \prod_{i=1}^N p(x_i)$ 。

对于每一个序列 x^N ，我们分配的码长取为香农码长向上取整：

$$l(x^N) = \lceil -\log_D P(x^N) \rceil \quad (16)$$

根据取整函数的性质 $y \leq \lceil y \rceil < y + 1$ ，我们有不等式：

$$-\log_D P(x^N) \leq l(x^N) < -\log_D P(x^N) + 1 \quad (17)$$

对该不等式求关于 X^N 的数学期望（即计算平均码长 L_N ）：

$$\sum_{x^N} P(x^N)(-\log_D P(x^N)) \leq \sum_{x^N} P(x^N)l(x^N) < \sum_{x^N} P(x^N)(-\log_D P(x^N)) + 1 \quad (18)$$

代入熵的定义 $H_D(X^N) = -\sum P(x^N) \log_D P(x^N)$ ，得到：

$$H_D(X^N) \leq L_N < H_D(X^N) + 1 \quad (19)$$

由于 X_i 是独立同分布 (i.i.d.) 的，联合熵具有可加性：

$$H_D(X^N) = N \cdot H_D(X) \quad (20)$$

代入不等式：

$$N \cdot H_D(X) \leq L_N < N \cdot H_D(X) + 1 \quad (21)$$

我们要考察的是“平均每个原始符号”的码长，即 $\bar{L} = \frac{L_N}{N}$ 。将上式除以 N ：

$$H_D(X) \leq \frac{L_N}{N} < H_D(X) + \frac{1}{N} \quad (22)$$

现在，令块长 $N \rightarrow \infty$ ，根据夹逼定理 (Squeeze Theorem)：

$$\lim_{N \rightarrow \infty} \frac{L_N}{N} = H_D(X) \quad (23)$$

□

4 4. 结论

综合第一部分和第二部分：

1. 任意编码的平均长度不能低于 $H_D(X)$ 。
2. 通过足够长的块编码，平均长度可以无限接近 $H_D(X)$ 。

因此，信息熵 $H_D(X)$ 是无损编码平均码长的下确界。