

信源编码理论基础技术手册

Source Coding Theory Technical Reference

工程技术归档

January 22, 2026

Abstract

摘要：本手册旨在为信息论与编码理论提供一套严谨的术语定义集。手册重点阐述了信源编码的基本构成元素（码元、码字），详细辨析了扩展编码与块编码的本质区别，并归纳了唯一可译码与前缀码的代数性质及存在性条件。

Contents

1	1. 基础术语定义 (Basic Terminology)	2
2	2. 编码分类体系 (Classification)	2
2.1	2.1 非奇异码 (Non-singular Code)	2
2.2	2.2 唯一可译码 (Uniquely Decodable, UD)	2
2.3	2.3 前缀码 (Prefix Code / Instantaneous Code)	3
3	3. 核心辨析：信源编码、扩展编码与块编码	4
3.1	3.4 对比总结表	5
4	4. 理论极限 (Fundamental Limits)	5

1 1. 基础术语定义 (Basic Terminology)

在讨论任何编码算法之前，必须明确构成编码的“原子”单位。设信源样本空间为 $\mathcal{X}$ ，编码字母表为 $\mathcal{D}$ 。

定义 1.1: 信源符号 (Source Symbol)

信息源产生的离散随机变量 X 的具体取值，记为 $x \in \mathcal{X}$ 。

- 例如：英文字母 $\{A, B, C, \dots\}$ 或天气状态 $\{, , \}$ 。

定义 1.2: 码元 (Code Element / Code Symbol)

构成编码输出序列的最小物理单位，来自字母表 $\mathcal{D}$ 。

- 字母表大小记为 $D = |\mathcal{D}|$ 。
- 最常见的是二进制 $D = 2$ ，码元为 $\{0, 1\}$ ，单位为比特 (bit)。
- 在代数几何码中，码元通常是有限域 $\mathbb{F}_q$ 中的元素。

定义 1.3: 码字 (Codeword)

赋予特定信源符号 x 的一串有限长度的码元序列。

$$C(x) = (d_1, d_2, \dots, d_l), \quad d_i \in \mathcal{D} \quad (1)$$

- 注意：码字是映射的结果字符串。

定义 1.4: 码长 (Code Length)

码字 $C(x)$ 中包含的码元个数，记为 $l(x)$ 或 $|C(x)|$ 。

- 平均码长 L 是所有码长的概率加权和： $L = \sum p(x)l(x)$ 。

2 2. 编码分类体系 (Classification)

依据解码的可行性和效率，编码方案被划分为严格的包含层级：

前缀码 $\subset$ 唯一可译码 $\subset$ 非奇异码

2.1 2.1 非奇异码 (Non-singular Code)

定义： 单个符号的映射是单射。即 $x_i \neq x_j \implies C(x_i) \neq C(x_j)$ 。

- **局限：** 仅保证“单词”不重复，不保证连成句子后能分开。

2.2 2.2 唯一可译码 (Uniquely Decodable, UD)

定义： 任意有限长的信源序列编码后，能被唯一地还原为原序列。即扩展映射 C^* 是单射。

- **判据：**必须满足 McMillan 不等式 $\sum D^{-l_i} \leq 1$ 。

2.3 2.3 前缀码 (Prefix Code / Instantaneous Code)

定义：没有任何一个码字是另一个码字的前缀 (Prefix-free)。

- **特性：**即时可译，无需缓冲区，无需回溯。
- **判据：**满足 Kraft 不等式 $\sum D^{-l_i} \leq 1$ 即可构造。
- **地位：**工程中最常用的无损编码类型。

3. 核心辨析：信源编码、扩展编码与块编码

这是本手册的核心部分。需严格区分“简单重复”与“整体优化”。

定义 3.1: 信源编码 (Source Coding)

最基础的映射操作。通常指将单个信源符号 x 映射为码字 $C(x)$ 。

$$C : \mathcal{X} \rightarrow \mathcal{D}^* \quad (2)$$

定义 3.2: 扩展编码 (Extension of a Code)

逻辑：机械拼接。

- 并不是设计新码，而是将原有的规则 C 应用于序列。
- 对于序列 $\mathbf{x} = (x_1, \dots, x_N)$ ，其 N 次扩展编码为：

$$C^*(\mathbf{x}) = C(x_1)C(x_2) \dots C(x_N) \quad (3)$$

- **目的：**用于定义和分析“唯一可译性”。如果 C^* 是单射，则 C 是唯一可译的。
- **效率：完全不变。**平均每个符号的码长依然是原码长 L 。无法压缩符号间的冗余。

定义 3.3: 块编码 (Block Coding)

逻辑：打包重组，整体优化。

- 将 N 个信源符号看作一个“超符号”向量 $\mathbf{X}^N$ 。
- 基于联合概率分布 $P(\mathbf{X}^N)$ 设计一个全新的映射函数 f 。

$$f : \mathcal{X}^N \rightarrow \mathcal{D}^* \quad (4)$$

- **关键点：**通常 $f(x_1x_2) \neq C(x_1)C(x_2)$ 。
- **目的：**利用大数定律，均摊整数化带来的量化误差，逼近熵极限。
- **效率：**随着 $N \rightarrow \infty$ ，平均每符号长度 $L_N/N \rightarrow H(X)$ 。

特性	扩展编码 (Extension)	块编码 (Block Coding)
输入对象	序列，但逐个处理	序列，整体作为一个大符号
编码规则	沿用旧规则 C	重新设计新规则 f
码字结构	旧码字的简单拼接	全新的比特流
压缩效率	不变 (L)	提高 (逼近 $H(X)$)
物理实现	无记忆，流式处理	需缓存 N 个符号，有延迟

3.1 3.4 对比总结表

4 4. 理论极限 (Fundamental Limits)

定义 4.1: 信息熵 (Entropy)

信源符号不确定性的度量，也是无损编码平均码长的下确界。

$$H_D(X) = - \sum_i p(x_i) \log_D p(x_i)$$

(5)

定义 4.2: 香农第一定理 (Source Coding Theorem)

对于无记忆信源，随着块编码长度 $N \rightarrow \infty$ ，平均每符号码长 $\bar{L}$ 可以任意逼近熵 $H_D(X)$ ，但绝不可能低于它。

$$\lim_{N \rightarrow \infty} \frac{L_N}{N} = H_D(X)$$

(6)